**UNIVERSIDAD DEL VALLE DE GUATEMALA**
**Data Science**
**Sección 11**
**Lynette García**




# Proyecto 1: Investigación de algoritmos de aprendizaje automático

**Gadiel Ocaña, 231270**
**Adrián González, 23152**
**José Ordoñez, 231329**
**José Antón, 221041**

**GUATEMALA, 1 de octubre de 2026**

# Revisión bibliográfica y selección preliminar de algoritmos de aprendizaje automático para la clasificación de la efectividad de unidades discursivas en ensayos argumentativos estudiantiles

## Introducción

La argumentación escrita es una habilidad central del pensamiento crítico y del desempeño académico en la educación secundaria, pero su evaluación es costosa, subjetiva y difícil de escalar, pues exige que evaluadores expertos lean y califiquen manualmente cada ensayo (Crossley et al., 2022). El presente proyecto aborda una versión específica de este problema: predecir si una unidad discursiva de un ensayo estudiantil es *Effective*, *Adequate* o *Ineffective*, a partir de su contenido textual y su tipo de discurso, mediante técnicas de aprendizaje automático.

El objetivo de este documento es doble. Primero, se presenta una revisión bibliográfica sobre los algoritmos de aprendizaje automático que se han empleado en problemas cercanos, a saber, la evaluación automática de ensayos, el análisis de la calidad argumentativa y la clasificación de texto. Segundo, a partir de esa revisión y de los hallazgos del análisis exploratorio previo, se realiza una selección preliminar de representaciones de texto y de modelos, justificando las razones de cada elección. Las fuentes provienen mayoritariamente de revistas indexadas; se incluyen además unas pocas publicaciones de congresos y talleres reconocidos del área, indicadas como tales en las referencias, cuando constituyen la fuente original de una técnica o del único estudio disponible sobre la tarea.

### Delimitación del problema

Cada observación del conjunto de datos contiene el fragmento de texto (*discourse_text*), su tipo discursivo (*discourse_type*: Lead, Position, Claim, Counterclaim, Rebuttal, Evidence o Concluding Statement) y su etiqueta de efectividad. La tarea puede formalizarse como una función que recibe el texto, el tipo discursivo y la longitud del fragmento y devuelve una de tres clases ordenadas:

$$f(\textit{discourse_text}, \textit{discourse_type}, \textit{longitud}) \rightarrow \{\text{Ineffective, Adequate, Effective}\}.$$

Esta formulación excluye explícitamente tres problemas vecinos: la detección automática de dónde están los componentes argumentativos en el ensayo (minería de argumentos; véase Stab y Gurevych, 2017), el análisis del ensayo completo y la predicción de su puntaje holístico. Dado que el tipo discursivo ya viene anotado, no se requieren modelos de segmentación ni de etiquetado de secuencias. En cambio, el análisis exploratorio del proyecto establece cuatro requisitos que condicionan la selección de algoritmos: (a) comparar representaciones de texto (TF-IDF y embeddings); (b) tratar el desbalance de clases, pues *Adequate* representa el 57.06 % de las observaciones e *Ineffective* solo el 17.58 %; (c) evitar la fuga de información, ya que los 36,765 fragmentos provienen de 4,191 ensayos y los fragmentos de un mismo ensayo no son independientes; y (d) tener en cuenta que, aunque la variable objetivo es multiclase, sus tres categorías poseen un orden natural.

## Revisión bibliográfica

### La evaluación automática de la escritura

La evaluación automática de la escritura busca construir sistemas que asignen puntuaciones o categorías de calidad a textos producidos por estudiantes. Las revisiones sistemáticas del área coinciden en que estos sistemas han evolucionado desde modelos basados en características diseñadas manualmente (longitud, riqueza léxica, ortografía, complejidad sintáctica, legibilidad) hacia representaciones distribuidas, redes neuronales y arquitecturas *Transformer* (Ke y Ng, 2019; Misgna et al., 2025; Ramesh y Sanampudi, 2022; Uto, 2021). Una distinción útil que atraviesa esta literatura es separar dos componentes de un sistema: la *representación* del texto, que extrae características, y el *algoritmo de predicción*, que las transforma en una calidad estimada (Misgna et al., 2025). Esta separación guía la organización de la presente revisión y permite comparar representaciones y clasificadores de forma controlada, tal como lo plantea el segundo objetivo específico del proyecto.

Conviene señalar que la mayor parte de esta literatura trata ensayos completos con un puntaje holístico o por rasgos. La clasificación de la efectividad de unidades discursivas individuales es un problema más reciente, ligado a la disponibilidad del corpus PERSUADE, de modo que gran parte de la evidencia aplicable se transfiere por analogía desde la evaluación de ensayos y desde la clasificación de texto en general.

**Representaciones tradicionales y clasificadores clásicos**

El enfoque tradicional representa el contenido mediante bolsa de palabras o ponderación TF-IDF (Salton y Buckley, 1988) y lo combina con características adicionales, como la longitud o indicadores sintácticos, para alimentar clasificadores como la regresión logística, las máquinas de vectores de soporte (Cortes y Vapnik, 1995), los bosques aleatorios (Breiman, 2001) o los métodos de *boosting* (Chen y Guestrin, 2016). Según las revisiones del área, estos métodos son eficientes, requieren menos datos y recursos computacionales y permiten examinar qué características influyen en cada predicción, aunque su capacidad para capturar relaciones semánticas es limitada (Ke y Ng, 2019; Ramesh y Sanampudi, 2022).

Un hallazgo relevante para este proyecto es el de Mayfield y Black (2020), quienes encontraron que el ajuste fino de BERT produjo un desempeño similar al de modelos clásicos en evaluación automática de ensayos, a un costo computacional significativamente mayor. Este resultado respalda construir primero una línea base lineal sólida antes de invertir en modelos profundos. En minería de argumentos, el trabajo de Stab y Gurevych (2017) sobre ensayos persuasivos combina características léxicas, sintácticas y estructurales con clasificadores supervisados, lo que ilustra que la ingeniería de características sigue siendo una estrategia vigente cuando se dispone de anotación discursiva.

**Representaciones basadas en embeddings**

Los *embeddings* buscan superar la limitación semántica de TF-IDF representando palabras o fragmentos como vectores densos en los que textos de significado similar quedan próximos. Sentence-BERT (Reimers y Gurevych, 2019) modifica una red BERT preentrenada mediante estructuras siamesas y de tripletes para producir representaciones de oraciones o párrafos comparables con similitud coseno, y puede usarse como extractor de características congelado seguido de un clasificador convencional. Esta alternativa es pertinente porque fragmentos de calidad argumentativa semejante pueden emplear vocabulario distinto, relación que TF-IDF no capta adecuadamente, y porque evita el costo de ajustar un Transformer completo.

**Redes neuronales profundas**

Las arquitecturas neuronales aplicadas a la evaluación de textos incluyen redes convolucionales, recurrentes (como LSTM; Hochreiter y Schmidhuber, 1997), mecanismos de atención y modelos jerárquicos. Taghipour y Ng (2016) mostraron que una red recurrente-convolucional sin ingeniería de características superaba a líneas base tradicionales en puntuación de ensayos. Uto (2021) revisa estos modelos, los organiza según el tipo de tarea de evaluación y destaca que eliminan buena parte de la necesidad de diseñar características manualmente, a cambio de mayor demanda de datos y cómputo y menor interpretabilidad. Dado que las unidades discursivas del presente conjunto son fragmentos cortos (mediana de 28 palabras), el beneficio de modelar dependencias largas con redes recurrentes es acotado, lo que reduce su atractivo frente a los Transformers preentrenados.

**Modelos Transformer**

Los Transformers como BERT (Devlin et al., 2019) y DeBERTa (He et al., 2021) producen representaciones contextuales, es decir, el vector de cada palabra depende de las que la rodean; DeBERTa mejora la arquitectura mediante atención desenredada que separa contenido y posición. En la competencia de Kaggle *Feedback Prize – Predicting Effective Arguments*, que utilizó datos de PERSUADE para la misma tarea de este proyecto, las soluciones ganadoras se basaron en modelos de lenguaje de gran escala (Baffour et al., 2023). Estas soluciones requieren ajuste fino con GPU y, en la práctica, ensambles de varios modelos, lo que implica un costo que debe sopesarse frente a las restricciones del proyecto. Por ello, y siguiendo la evidencia de Mayfield y Black (2020), el ajuste fino de un Transformer se plantea aquí como extensión opcional y no como punto de partida.

**El corpus PERSUADE y la tarea de efectividad**

El conjunto de datos procede del corpus PERSUADE. Su primera versión incluye más de 25,000 ensayos argumentativos escritos por estudiantes estadounidenses de sexto a duodécimo grado, anotados con siete elementos discursivos mediante un proceso de doble calificación ciega con adjudicación total (Crossley et al., 2022). La versión 2.0 añadió puntuaciones de efectividad para cada elemento discursivo y puntajes holísticos para los ensayos, por lo que constituye la fuente más directamente relacionada con el problema investigado (Crossley et al., 2024). La escala de efectividad (*Ineffective*, *Adequate*, *Effective*) mide qué tan bien el elemento sostiene la posición global del autor (Baffour et al., 2023). En una línea cercana, Wachsmuth et al. (2017) propusieron una taxonomía de dimensiones de calidad argumentativa y evaluaron su viabilidad computacional, lo que sustenta que la calidad de un argumento puede modelarse a partir de su texto.

**Desbalance de clases, métricas y validación**

El desbalance de clases sesga a los algoritmos hacia la clase mayoritaria y vuelve engañosa a la exactitud global. La literatura distingue estrategias a nivel de datos (sobremuestreo, submuestreo) y a nivel de algoritmo (aprendizaje sensible al costo, como la ponderación de clases) (He y Garcia, 2009). SMOTE (Chawla et al., 2002) genera ejemplos sintéticos de la clase minoritaria interpolando entre vecinos en el espacio de características, por lo que es natural aplicarlo sobre representaciones densas, como los embeddings, y menos sobre vectores TF-IDF dispersos. En cuanto a la métrica, Sokolova y Lapalme (2009) analizan las medidas de desempeño para clasificación y sus variantes de promediado; el F1 macro, que promedia el F1 de cada clase con el mismo peso, es coherente con el objetivo del proyecto al no permitir que la clase mayoritaria domine la evaluación.

Respecto a la validación, cuando los datos tienen estructura jerárquica (aquí, fragmentos anidados en ensayos), la validación cruzada con particiones aleatorias produce estimaciones de desempeño demasiado optimistas porque observaciones relacionadas aparecen en entrenamiento y validación (Roberts et al., 2017). Este fenómeno es una forma de fuga de información (Kaufman et al., 2011). La mitigación consiste en particionar por grupo, en este caso por *essay_id*, preservando además la proporción de clases en cada pliegue. Las herramientas para ello están disponibles en *scikit-learn* (Pedregosa et al., 2011).

**Equidad y limitaciones**

Baffour et al. (2023) analizaron las soluciones ganadoras de la serie Feedback Prize y reportaron desempeño según raza/etnicidad, condición económica y estatus de estudiante de inglés como segunda lengua. Encontraron sesgo mínimo en la competencia de identificación de elementos discursivos, pero sesgo moderado en la de predicción de efectividad. Por ello, un F1 macro aceptable no debe interpretarse como evidencia de que el modelo es un evaluador objetivo. Dado que el conjunto de entrenamiento del proyecto no incluye variables demográficas, esta limitación no podrá auditarse directamente y debe declararse como tal.

**Tabla 1**

*Síntesis de los enfoques revisados y su pertinencia para el proyecto*

| Enfoque | Representación | Algoritmos típicos | Ventajas | Limitaciones | Fuentes |
|---|---|---|---|---|---|
| Clásico | Bolsa de palabras, TF-IDF, características manuales | Regresión logística, SVM, bosques aleatorios, *boosting* | Eficiente, interpretable, línea base fuerte | Semántica limitada | Salton y Buckley (1988); Cortes y Vapnik (1995); Breiman (2001); Chen y Guestrin (2016) |
| Embeddings congelados | Vectores densos (Sentence-BERT) | Regresión logística, MLP, *boosting* sobre embeddings | Captura similitud semántica sin ajustar el modelo | Menos interpretable; vectores no adaptados a la tarea | Reimers y Gurevych (2019) |
| Redes profundas | Embeddings aprendidos en la red | CNN, LSTM, atención | Aprende rasgos sin diseño manual | Más datos y cómputo; opaca | Taghipour y Ng (2016); Uto (2021) |
| Transformers con ajuste fino | Representaciones contextuales | BERT, DeBERTa | Mejor desempeño reportado en la tarea de Kaggle | Costo computacional alto; ganancia no siempre amplia sobre modelos clásicos; sesgo moderado documentado | Devlin et al. (2019); He et al. (2021); Mayfield y Black (2020); Baffour et al. (2023) |

*Nota.* Elaboración propia a partir de la literatura citada.

## Selección preliminar de algoritmos

### Criterios de selección

La selección se fundamenta en cinco criterios derivados de la revisión y del análisis exploratorio: (a) cumplir los objetivos específicos del proyecto, es decir, al menos dos representaciones de texto y tres modelos; (b) tener evidencia previa en tareas cercanas; (c) admitir ponderación de clases o un tratamiento equivalente del desbalance; (d) ser viable con los recursos computacionales disponibles para un proyecto de curso; y (e) permitir incorporar *discourse_type* y la longitud, que el análisis exploratorio identificó como predictores con asociación débil pero significativa con la efectividad (V de Cramér = 0.127).

**Representaciones del texto**

- **R1. TF-IDF** sobre unigramas y bigramas de palabras (y, como variante, n-gramas de caracteres), concatenado con *discourse_type* codificado en *one-hot* y con las longitudes en caracteres y palabras (transformadas logarítmicamente, dada la fuerte asimetría observada). Se elige por su eficiencia, su interpretabilidad y su papel de línea base (Salton y Buckley, 1988; Mayfield y Black, 2020).
- **R2. Embeddings de Sentence-BERT** congelados, concatenados con las mismas variables auxiliares. Se elige porque capturan similitud semántica que TF-IDF no recoge (Reimers y Gurevych, 2019) sin el costo del ajuste fino.

**Modelos seleccionados**

Los modelos se organizan en un núcleo obligatorio, que cubre los objetivos específicos, y una extensión condicionada a tiempo y recursos.

***Núcleo***

- **Regresión logística multinomial (con ponderación de clases).** Es la línea base principal: rápida, interpretable y con probabilidades calibradas razonablemente, útiles si se desea ajustar umbrales de decisión para maximizar el F1 macro. Se evaluará con R1 y R2.
- **SVM lineal.** Los clasificadores de margen máximo (Cortes y Vapnik, 1995) funcionan bien en espacios de alta dimensión y dispersos como el de TF-IDF, y admiten *class_weight*. Se evaluará con R1 y R2.
- **Bosque aleatorio o *boosting* de gradiente (XGBoost).** Los ensambles de árboles (Breiman, 2001; Chen y Guestrin, 2016) capturan interacciones no lineales entre el tipo discursivo, la longitud y el contenido que los modelos lineales no representan, por ejemplo, que cierta longitud sea señal de efectividad en *Claim* pero no en *Evidence*. Se aplicarán sobre R2, o sobre R1 reducida con SVD, porque los árboles manejan mal vectores dispersos de muy alta dimensión.

***Extensión opcional***

- **Ajuste fino de un Transformer** (DeBERTa-v3 o una variante destilada), con el tipo discursivo antepuesto al texto como marca. Se justifica por el desempeño de las soluciones ganadoras de la competencia (Baffour et al., 2023; He et al., 2021) y se ejecutaría únicamente si hay GPU disponible y si el núcleo deja un margen claro frente al objetivo de F1 macro. Se declara como opcional por la evidencia de costo-beneficio de Mayfield y Black (2020).
- **Perceptrón multicapa sobre embeddings** como paso intermedio entre los clasificadores lineales y el ajuste fino.

**Alternativas consideradas y descartadas**

No se emplearán CRF ni redes de grafos, pues sirven para etiquetar secuencias o modelar relaciones entre componentes argumentativos, y aquí los componentes ya vienen delimitados y tipados. Tampoco se usarán Transformers de contexto largo como Longformer, porque las unidades son cortas (la más larga tiene 836 palabras y la mediana, 28) y el ensayo completo no es la unidad de análisis. Las redes LSTM y CNN se descartan como primera opción: la revisión no muestra una ventaja que compense su costo frente a embeddings preentrenados en fragmentos cortos (Uto, 2021). Los modelos ordinales dedicados no se incluyen en el núcleo; si se explora el orden natural de las clases, se hará de forma simple, por ejemplo mediante el ajuste de umbrales sobre probabilidades.

**Estrategia experimental asociada**

- **Partición:** validación cruzada estratificada y agrupada por *essay_id*, con un conjunto de prueba reservado también por ensayo, para evitar la fuga de información (Kaufman et al., 2011; Roberts et al., 2017). Todo el preprocesamiento (ajuste de TF-IDF, remuestreo) se ajustará únicamente dentro de cada pliegue de entrenamiento.
- **Desbalance:** ponderación de clases como estrategia por defecto; SMOTE solo como comparación sobre R2 y dentro de los pliegues (He y Garcia, 2009; Chawla et al.,

2002).

- **Métricas:** F1 macro como métrica principal (objetivo del proyecto: F1 macro mayor o igual a 0.55), complementada con F1 por clase, matriz de confusión y la métrica que defina la competencia (Sokolova y Lapalme, 2009). Se incluirá un clasificador trivial de clase mayoritaria como referencia mínima.
- **Ajuste de hiperparámetros:** búsqueda en rejilla o aleatoria dentro de la validación cruzada agrupada, con *scikit-learn* (Pedregosa et al., 2011).
- **Control de variables:** cada modelo del núcleo se evaluará con R1 y con R2 bajo la misma partición, de modo que las diferencias puedan atribuirse a la representación o al algoritmo y no al diseño experimental.

**Tabla 2**

*Resumen de la selección preliminar de algoritmos*

| Modelo | Representación | Papel | Justificación principal | Fuente de respaldo |
|---|---|---|---|---|
| Regresión logística | R1, R2 | Núcleo (línea base) | Eficiente, interpretable, probabilidades útiles | Mayfield y Black (2020) |
| SVM lineal | R1, R2 | Núcleo | Adecuada para texto disperso y de alta dimensión | Cortes y Vapnik (1995) |
| Bosque aleatorio / XGBoost | R2 (o R1 con SVD) | Núcleo | Captura interacciones entre tipo, longitud y contenido | Breiman (2001); Chen y Guestrin (2016) |
| MLP sobre embeddings | R2 | Opcional | Paso intermedio no lineal | Reimers y Gurevych (2019) |
| DeBERTa con ajuste fino | Contextual | Opcional | Mejor desempeño reportado en la tarea | Baffour et al. (2023); He et al. (2021) |

*Nota.* R1 = TF-IDF más variables auxiliares; R2 = embeddings de Sentence-BERT más variables auxiliares.

### Riesgos y limitaciones

Existen tres riesgos principales. Primero, la longitud y el tipo discursivo están correlacionados entre sí, por lo que su aporte al modelo puede estar mezclado; se analizará su efecto con y sin estas variables. Segundo, el objetivo de F1 macro mayor o igual a 0.55 se fijó antes de contar con resultados, por lo que su dificultad real solo se conocerá al evaluar la línea base. Tercero, la ausencia de variables demográficas impide auditar sesgos, y la literatura documenta sesgo moderado en esta misma tarea (Baffour et al., 2023); los resultados deben presentarse con esa salvedad.

## Conclusiones

La literatura revisada indica que la clasificación de la efectividad de unidades discursivas combina dos decisiones separables, la representación del texto y el algoritmo de predicción, y que los Transformers con ajuste fino ofrecen el mejor desempeño reportado a un costo elevado, mientras que los modelos clásicos bien construidos constituyen una línea base competitiva (Baffour et al., 2023; Mayfield y Black, 2020). En consecuencia, se propone un núcleo de tres familias de clasificadores (lineal logístico, SVM lineal y ensambles de árboles) evaluados sobre dos representaciones (TF-IDF y Sentence-BERT) con validación agrupada por ensayo, y se reserva el ajuste fino de DeBERTa como extensión condicionada a los recursos disponibles. Este diseño cumple los objetivos específicos del proyecto, trata explícitamente el desbalance y la dependencia entre fragmentos, y permite atribuir las diferencias de desempeño a la representación o al modelo.

## Referencias

Baffour, P., Saxberg, T., y Crossley, S. (2023). Analyzing bias in large language model solutions for assisted writing feedback tools: Lessons from the Feedback Prize competition series. En *Proceedings of the 18th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2023)* (pp. 242–246). Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.bea-1.21

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research, 16*, 321–357. https://doi.org/10.1613/jair.953

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine Learning, 20*(3), 273–297. https://doi.org/10.1007/BF00994018

Crossley, S. A., Baffour, P., Tian, Y., Picou, A., Benner, M., y Boser, U. (2022). The persuasive essays for rating, selecting, and understanding argumentative and discourse elements (PERSUADE) corpus 1.0. *Assessing Writing, 54*, Artículo 100667. https://doi.org/10.1016/j.asw.2022.100667

Crossley, S. A., Tian, Y., Baffour, P., Franklin, A., Benner, M., y Boser, U. (2024). A large-scale corpus for assessing written argumentation: PERSUADE 2.0. *Assessing Writing, 61*, Artículo 100865. https://doi.org/10.1016/j.asw.2024.100865

Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational*

*Linguistics: Human Language Technologies, Volume 1* (pp. 4171–4186). Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1423

He, H., y Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263–1284. https://doi.org/10.1109/TKDE.2008.239

He, P., Liu, X., Gao, J., y Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. En *International Conference on Learning Representations (ICLR 2021)*. https://arxiv.org/abs/2006.03654

Hochreiter, S., y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Kaufman, S., Rosset, S., y Perlich, C. (2011). Leakage in data mining: Formulation, detection, and avoidance. En *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 556–563). ACM. https://doi.org/10.1145/2020408.2020496

Ke, Z., y Ng, V. (2019). Automated essay scoring: A survey of the state of the art. En *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence* (pp. 6300–6308). International Joint Conferences on Artificial Intelligence Organization. https://doi.org/10.24963/ijcai.2019/879

Mayfield, E., y Black, A. W. (2020). Should you fine-tune BERT for automated essay scoring? En *Proceedings of the Fifteenth Workshop on Innovative Use of NLP for Building Educational Applications* (pp. 151–162). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.bea-1.15

Misgna, H., On, B.-W., Lee, I., y Choi, G. S. (2025). A survey on deep learning-based automated essay scoring and feedback generation. *Artificial Intelligence Review, 58*(2), Artículo 36. https://doi.org/10.1007/s10462-024-11017-5

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Ramesh, D., y Sanampudi, S. K. (2022). An automated essay scoring systems: A systematic literature review. *Artificial Intelligence Review, 55*(3), 2495–2527. https://doi.org/10.1007/s10462-021-10068-2

Reimers, N., y Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (pp. 3982–3992). Association for Computational Linguistics. https://doi.org/10.18653/v1/D19-1410

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., y Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Salton, G., y Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management, 24*(5), 513–523. https://doi.org/10.1016/0306-4573(88)90021-0

Sokolova, M., y Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management, 45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Stab, C., y Gurevych, I. (2017). Parsing argumentation structures in persuasive essays. *Computational Linguistics, 43*(3), 619–659. https://doi.org/10.1162/COLI_a_00295

Taghipour, K., y Ng, H. T. (2016). A neural approach to automated essay scoring. En *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing* (pp. 1882–1891). Association for Computational Linguistics. https://doi.org/10.18653/v1/D16-1193

Uto, M. (2021). A review of deep-neural automated essay scoring models. *Behaviormetrika, 48*(2), 459–484. https://doi.org/10.1007/s41237-021-00142-y

Wachsmuth, H., Naderi, N., Hou, Y., Bilu, Y., Prabhakaran, V., Thijm, T. A., Hirst, G., y Stein, B. (2017). Computational argumentation quality assessment in natural language. En *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers* (pp. 176–187). Association for Computational Linguistics. https://doi.org/10.18653/v1/E17-1017